

سوال ۱: اینها علت استفاده از اعتبار رشتی مقابل (Cross - Validation) چیست؟

دلیل از Cross - Validation این است که به چه میزان مدل می تواند در داده های جدید که در آن ها train نهاده بود به خوبی پیش بینی ها را انجام دهد.

• دلایل استفاده از این روش:

۱) جلوگیری از اورفیت (Overfitting) کردن مدل روی داده های ما: زمانی که یک مدل بیش از حد به داده های آموزشی وابسته شده و نتایج خوبی را در آن وابسته می شود. آمارهای نشان دهنده هر چه به وابستگی بیشتری بین داده ها به مدل ما Overfitting کرده است و این یعنی به هر چه وابستگی بیشتری بین داده ها به مدل ما Overfitting کرده است. مدل اعتبار رشتی کمک می کند تا مدل به گونه ای آموزش دیده باشد که در داده های test نیز به خوبی کار کند.

• به نوعی در این حالت ما داریم داده ها را به چندین بخش در train و test تقسیم بندی می کنیم.

۲) استفاده از اعتبار داده ها:

ی طوری که در حالت های داده ها را به دو مجموعه train و test تقسیم بندی کرده ایم که این روش می تواند منجر به ارزیابی دقیق تر و پیش بینی بهتر از داده های جدید آموزش مدل باشد. که با استفاده از اعتبار رشتی مقابل می توان از داده های جدید برای آموزش و هم برای تست استفاده کرد. در نتیجه داده های ما به دست چندین استفاده می شوند.

• در مورد روش های اعتبار رشتی:

۱) k-fold - این روش شامل تقسیم داده ها به k بخش های معادل است. یکی از این بخش ها را به عنوان test و بقیه را به عنوان train در نظر می گیریم. این کار را k بار تکرار می کنیم و میانگین نتایج را محاسبه می کنیم. و با باقی دست داده ها.

تکثیر در این اعتبار رشتی (test) و تقسیم به عنوان train به نوعی در نظر می گیریم که به بخش های مختلف داده های آموزشی (k) با یکدیگر مقایسه می کنیم.

مذرت ما - از باره ها به دست که آید و تمام است و می کند.
که چون در هر ساله بعضی فصلی تمام که از باره ها از ناسی می کنند و در به خوبی
از در آن حرکت ما: trans می شود.

مطالب ۱۵۱ بزرگ بارش حسابات به طایفه قابل تبعی از این مقام یافت

• LOOCV: Leave-One-Out-Cross-Validation:

این زودتر حادش خافه از لاد که بی باره در هر کد از رنگ غوغه بیل است استاده میسر و
و باقی با صافه این استاده بیل استاده میسر و

و این فراموشی را به تندرستی و تقوی که حاصل آنست به قدری که
باب به تندرستی و باران آنست که

بابہ بہادر ۵ بار ران تم لکھنؤ
فریٹ ہا۔ این روٹ پلے عرف اسٹندہ ۱۰/۵ ص ۱۰۵ آئینہ روزی را لکھنؤ میل را بہ خوب
Train

و تشریح من فی الحاشیاء بر این مباحثه و توضیح آن.

تغیہ معافی ای دم کھلوان ایست کہ از قلم محاسبی بیست و پنج است چنان دارم و در هر یک از کارها
که بار آنست هم از قلم محاسبی

• فصل ۱۱ متوزن فاصله اقلیدس :

$$D(x, y) = \sqrt{\sum_{k=1}^d (x_k - y_k)^2}$$

• حال اگر در ربع را در یک مقدار صحت داشته باشد. باز هم میسر فاصله اقلیدس را داریم.
 • بندیست خصوصیات یک میسر فاصله اقلیدس :
 • چون هر دو به یک میسر (q_k)
 • لی فاصله اقلیدس.

$$D(x, y) = \sqrt{\sum_{k=1}^d (x_k - y_k)^2}$$

$$\sqrt{\sum_{k=1}^d q_k^2 (x_k - y_k)^2} = \sqrt{\sum_{k=1}^d q_k^2 |x_k - y_k|^2}$$

① میزبانی برد : چون در هر دو لی $(x_k - y_k)^2$ یک میسر فاصله اقلیدس q_k^2 که
 • پس نتیجه آن یک میسر فاصله اقلیدس چون $D(x, y)$ بود.

• ایچون که و q_k^2 و $(x_k - y_k)^2$ پس پس x_k و y_k مقدار آن هست
غیر متغیبات.

② Identity of Indiscernibles که $D(x, y) = 0$ اگر و فقط اگر $x = y$ باشد

• زیر آن چون q_k میزبانی مقدار تفاوت مقدار $(x_k - y_k)$ لا فاصله اقلیدس که
پس q_k مقدار تفاوت مقدار فاصله اقلیدس که $x = y$ باشد.

③ تفاوت $D(x, y) = D(y, x)$ که زیر آن چون که $(x_k - y_k)^2 = (y_k - x_k)^2$ باشد

④ و q_k پس مقدار تفاوت مقدار فاصله اقلیدس که $x = y$ باشد

$$D(x', y') = \sqrt{\sum_{k=1}^d q_k^2 (\lambda_k - y_k)^2}$$

$$D(y', \lambda') = \sqrt{\sum_{k=1}^d q_k^2 (y_k - \lambda_k)^2}$$

ویکتور این دو نام برابر متعین

$(\lambda_{1k} - y_k)^2 = (y_k - \lambda_{1k})^2$

④ نام برابر نیست

از آن جایی که فاصله اتالیقی استاندارد نام برابر نیست و اگر آورده می کنند و تفاوتی ب q_k آن افزودند

است سیم چندین برآورد میرد.

ل۱ Regularization و ل۲ Regularization

هدف این است که مدل را از بیش‌برازش (overfitting) جلوگیری کنیم. به این منظور، ما یک جریمه (penalty) به تابع هزینه اضافه می‌کنیم که بر اساس ضرایب مدل محاسبه می‌شود. این جریمه باعث می‌شود که مدل به دنبال پیدا کردن ضرایب بزرگ نباشد و به همین دلیل، تعمیم‌پذیری مدل افزایش می‌یابد.

$$L_1 \text{ Penalty} = \lambda \sum_{i=1}^d |w_i|$$

که در این جا λ یک ضریب تنظیم‌کننده (regularization parameter) است که میزان جریمه را کنترل می‌کند. مقدار λ باید به گونه‌ای انتخاب شود که تعادل مناسبی بین کاهش خطای آموزش و جلوگیری از بیش‌برازش برقرار باشد. L_1 این است که من است که یعنی از ضرایب کوچک‌تر استفاده می‌کند. L_2 ریشه دوم ضرایب را در نظر می‌گیرد و به همین دلیل، ضرایب بزرگ را بیشتر جریمه می‌کند.

در مدل L_2 به این صورت است که:

$$L_2 \text{ Penalty} = \lambda \sum_{i=1}^d w_i^2$$

که در این حالت، جریمه بر اساس مربع ضرایب محاسبه می‌شود. این به این دلیل است که ضرایب بزرگ را بیشتر جریمه می‌کند و به همین دلیل، ضرایب مدل کوچک‌تر می‌شوند. این به ما کمک می‌کند تا از بیش‌برازش جلوگیری کنیم.

L_2 معمولاً در مدل‌های خطی و شبکه‌های عصبی استفاده می‌شود.

در حالی که L_1 در مدل‌های خطی و شبکه‌های عصبی استفاده می‌شود. L_1 به ما کمک می‌کند تا ضرایب اضافی را حذف کنیم و به همین دلیل، مدل ما ساده‌تر می‌شود. این به ما کمک می‌کند تا از بیش‌برازش جلوگیری کنیم.

مدل بهینه‌تری خواهد بود که ضرایب اضافی را حذف کند. به این دلیل، L_1 به ما کمک می‌کند تا از بیش‌برازش جلوگیری کنیم.

• فواید مقدار کمین w را از آن داریم پس باید از $L(w)$ مینیمم w را مشتق گرفته
و مساوی با صفر کنیم :

$$L(w) = \sum_{i=1}^n (w^T x_i - y_i)^2 + \lambda \|w\|_2^2$$

• in Matrix form:

$$L(w) = (Xw - y)^T (Xw - y) + \lambda w^T w$$

$$\Rightarrow \nabla_w L(w) = 2X^T (Xw - y) + 2\lambda w$$

حالت گیری از این باید به این صورت کنیم

$$2X^T (Xw - y) + 2\lambda w = 0$$

$$X^T (Xw - y) - \lambda w = 0$$

$$(X^T X + \lambda I) w = X^T y$$

$$\Rightarrow \boxed{w = (X^T X + \lambda I)^{-1} X^T y} = \underline{(X^T X + \lambda I)^{-1} X^T y}$$

• به صورتی w

مسئله ۳ :

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

• وابسته‌های میان x و y این شک است که:

$$y_i = wx_i + \epsilon_i$$

$$\epsilon_i \sim N(0, 1)$$

نویز غشایی

• میان x و y وابسته‌ای که ϵ_i نویزی است که از نویزهای y دارد.
 • میان x و y وابسته‌ای که ϵ_i نویزی است که از نویزهای y دارد.

~~y_i~~

$$y_i \sim N(wx_i, 1)$$

• میان x و y وابسته‌ای که ϵ_i نویزی است که از نویزهای y دارد.

$$p(y_i | w) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y_i - wx_i)^2}{2}\right)$$

• میان x و y وابسته‌ای که ϵ_i نویزی است که از نویزهای y دارد.

$$p(D | w) = \prod_{i=1}^n p(y_i | w) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y_i - wx_i)^2}{2}\right)$$

$$\log(p(D | w)) = \sum_{i=1}^n \log \frac{1}{\sqrt{2\pi}} - \frac{(y_i - wx_i)^2}{2}$$

$$= \sum_{i=1}^n \left(\log \frac{1}{\sqrt{2\pi}} \right) - \frac{1}{2} \sum_{i=1}^n (y_i - wx_i)^2$$

Constant

$$\Rightarrow \log p(D | w) = \text{Constant} - \frac{1}{2} \sum_{i=1}^n (y_i - wx_i)^2$$

⑦

maximizing on the log-likelihood:

$$\Rightarrow \max_w \log P(D|w) = \max_w \left(-\frac{1}{2} \sum_{i=1}^n (y_i - wx_i)^2 \right)$$

$$= \min \sum_{i=1}^n (y_i - wx_i)^2$$

minimize $\sum_{i=1}^n (y_i - wx_i)^2$
 minimize the sum of squared errors

$$\Rightarrow \arg \max_w \log P(D|w) = \arg \min_w \sum_{i=1}^n (y_i - wx_i)^2$$

و ما به دنبال مجموع : رابطه ی بین ورودی و خروجی تابع این صورت مدل ساخته می شود :

$$y = \exp(wx) = \underline{y = e^{wx}}$$

مجموع داده های که برآورد می دهیم $\rightarrow J = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$

• برای تابع هزینه ی مجموع مجذور خطا داریم :

Cost of SSE \rightarrow Sum of Squared Errors

$$J(w) = \sum_{i=1}^n (y_i - \exp(wx_i))^2$$

$$w_{t+1} = w_t - \alpha \frac{\partial J(w)}{\partial w}$$

• بهای اساسی در هر بار کاهش : α

learning rate

$$\frac{\partial J(w)}{\partial w} = \frac{\partial}{\partial w} \left(\sum_{i=1}^n (y_i - e^{wx_i})^2 \right)$$

$$= (2) \sum_{i=1}^n (y_i - e^{wx_i}) \cdot \frac{\partial}{\partial w} (e^{y_i} - e^{wx_i})$$

$$= 2 \sum_{i=1}^n (y_i - e^{wx_i}) e^{wx_i} x_i$$

$$\Rightarrow \boxed{w_{t+1}} = w_t + \alpha \sum_{i=1}^n (y_i - e^{(w_t)x_i}) e^{(w_t)x_i} \cdot x_i$$

②

$$\frac{\partial J(w)}{\partial w} = 0 \rightarrow \underline{y_i = e^{x_i w}}$$

$$\prod_{i=1}^n y_i e^{y_i x_i w} = \prod_{i=1}^n e^{y_i x_i w} e^{y_i x_i w} = \prod_{i=1}^n y_i x_i e^{w x_i}$$
