

مسئله اصلی: $\min_{\alpha} \sum_{i=1}^n \max(0, \alpha y_i - x_i^T \alpha)$
 در این مدل ما می‌خواهیم خطی را پیدا کنیم که بتواند داده‌ها را به خوبی جدا کند.
 هدف ما این است که خطی را پیدا کنیم که بتواند داده‌ها را به خوبی جدا کند.

$$\alpha_{t+1} = \arg \min_{\alpha_{t+1}} f(x_{t+1} + \alpha p_{t+1})$$

• فرمولی برای به‌روزرسانی α داریم.

• در این مدل ما می‌خواهیم خطی را پیدا کنیم که بتواند داده‌ها را به خوبی جدا کند.

① مقداردهی اولیه: α_0 (تصادفی) و p_0 (تصادفی) را انتخاب می‌کنیم.

② محاسبه خطی: $f(x_{t+1} + \alpha p_{t+1})$ را محاسبه می‌کنیم و آن را با مقدار قبلی مقایسه می‌کنیم.

$$\alpha_{t+1} = \arg \min_{\alpha_{t+1}} f(x_{t+1} + \alpha p_{t+1})$$

③ به‌روزرسانی: α_{t+1} را به α_t و p_{t+1} را به p_t به‌روزرسانی می‌کنیم.

این فرآیند را تا زمانی که خطی را پیدا کنیم که بتواند داده‌ها را به خوبی جدا کند، ادامه می‌دهیم.
 (این فرآیند را می‌توانیم به صورت زیر هم بنویسیم)

جست‌وجوی خطی که بتواند داده‌ها را به خوبی جدا کند.
 به عبارت دیگر: $\min_{\alpha} \sum_{i=1}^n \max(0, \alpha y_i - x_i^T \alpha)$

به عبارت دیگر: $\min_{\alpha} \sum_{i=1}^n \max(0, \alpha y_i - x_i^T \alpha)$

④ این فرآیند را تا زمانی که خطی را پیدا کنیم که بتواند داده‌ها را به خوبی جدا کند، ادامه می‌دهیم.

• این مسئله را می‌توانیم به صورت زیر هم بنویسیم.

بعضی‌ها این مسئله را به صورت زیر هم بنویسند:

$$\alpha = \arg \min_{\alpha} f(x + \alpha p)$$

① جست‌وجوی خطی: α را به‌روزرسانی می‌کنیم.
 ② جست‌وجوی خطی: p را به‌روزرسانی می‌کنیم.

در این مدل ما می‌خواهیم خطی را پیدا کنیم که بتواند داده‌ها را به خوبی جدا کند.
 به عبارت دیگر: $\min_{\alpha} \sum_{i=1}^n \max(0, \alpha y_i - x_i^T \alpha)$

① قاعده‌های به‌روزرسانی: $\alpha_{t+1} = \alpha_t + \eta (y_t - x_t^T \alpha_t)$
 ② خطی که می‌خواهیم پیدا کنیم: x_t

مسئله ۱) بخش د) جدول ضرایب زنجیره‌ای
 بدین شکل است:

$$f(x_1, x_2) = (x_1 + x_2^2)^2$$

مقادیر x_1 و x_2 به هم وابسته
 می‌باشند:

$x_1^T = (0, 1)$ $p^T = (-1, -1)$ مورد نادرست

در اینجا باید گزینه ب را انتخاب کنیم:

$$\nabla f(x_1, x_2) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2} \right) = (2(x_1 + x_2^2), 4x_2(x_1 + x_2^2))$$

$x_1^T = (0, 1) \Rightarrow \nabla f(0, 1) = (2(1), 4(1)(1)) = (2, 4)$

$\nabla f(x^T) p^T = (2, 4) \cdot (-1, -1) = -2$

مورد نادرست است زیرا
 ضرایب هم‌جهتی ندارند

حالا باید گزینه ج را انتخاب کنیم که رابطه به α به عنوان پارامتر

$p^T = (-1, 1)$, $x^T = (0, 1)$

بدین شکل ضرایب هم‌جهتی می‌باشند:

$$x^T + \alpha p^T = (0, 1) + \alpha(-1, 1) = (-\alpha, 1 + \alpha)$$

این نقطه ضرایب هم‌جهتی خواهد بود.

حالا باید این رابطه به α قرار دهیم:

$$f(-\alpha, 1 + \alpha) = (-\alpha + (1 + \alpha)^2)^2 = (\alpha^2 - 3\alpha + 1)^2$$

به سبب α متغیر است.

$$\frac{d}{d\alpha} (\alpha^2 - 3\alpha + 1)^2 = 2(\alpha^2 - 3\alpha + 1)(2\alpha - 3) = 0$$

$$\alpha = \frac{3 \pm \sqrt{5}}{2}$$

$$\alpha = \frac{3}{2}$$

$$\alpha = \frac{3}{2}$$

پس این گزینه ج را باید انتخاب کنیم.

$$\alpha = \frac{3 \pm \sqrt{5}}{2}$$

Newton's Method:

$$J(x) = J(x_0) + (x - x_0)^T \nabla J(x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 J(x_0) (x - x_0)$$

تقریب دوم (2) به عنوان یک حد و حدود
حل اگر فرض شود که $J(x)$ در یک نقطه است که

$$\nabla J(x_0) = 0$$

$$\nabla J(x_0) + \nabla^2 J(x_0) (x_1 - x_0) = 0 \Rightarrow x_1 = x_0 - H^{-1}(x_0) \nabla J(x_0)$$

برای تعیین اینکه آیا روش نیوتن
از آن خواص دارد
عبارت به این صورت داریم: جواب روش نیوتن:

1) حاصل هینست که منفی باشد. در $Q(x)$ باید به این دلیل که اصل یکبار زیاد باشد
این محاسبه می‌تواند از محاسبات اولیه ساده‌تر و محاسبه آن در آن

ج) تغییرات محسوس در $J(x)$ با روش نیوتن به این دلیل که محسوس شود که $J(x)$ به تدریج
در حال کاهش است و به این دلیل که $J(x)$ به تدریج به سمت $Positive Definit$
تبدیل می‌شود و به این دلیل که $J(x)$ به تدریج به سمت $Positive Definit$

و حالت دیگر این است که $J(x)$ به سمت $minimum$ می‌رود و به این دلیل که $J(x)$ به تدریج به سمت $minimum$
و به این دلیل که $J(x)$ به تدریج به سمت $minimum$ می‌رود و به این دلیل که $J(x)$ به تدریج به سمت $minimum$

حل چند روش دیگر روش نیوتن را می‌توان به روش نیوتن اضافه کرد و به این دلیل که $J(x)$ به تدریج به سمت $minimum$
1) اولین روش نیوتن
2) روش نیوتن که در آن $J(x)$ به تدریج به سمت $minimum$ می‌رود و به این دلیل که $J(x)$ به تدریج به سمت $minimum$
3) روش نیوتن که در آن $J(x)$ به تدریج به سمت $minimum$ می‌رود و به این دلیل که $J(x)$ به تدریج به سمت $minimum$

لامرئیس (2) : حال این دو روش را به یکدیگر (ارزش) بدهیم Quasi-Newton و DFB و BFGS که توضیح می‌دهیم:

روش های بهینه‌سازی: Quasi-Newton Method: $\theta_{i+1} = \theta_i - \alpha_i \nabla I(\theta_i)$
 Step-size: α_i (مقدار گام) $\nabla I(\theta_i)$ (گرادیان)

در روش BFGS: $S_{i+1} = S_i + \alpha_i$ $\nabla I(\theta_i)$

$$S_{i+1} = \left(I - \frac{\Delta \theta_i \Delta \theta_i^T}{\Delta \theta_i^T \Delta \theta_i} \right) S_i \left(I - \frac{\Delta \theta_i \Delta \theta_i^T}{\Delta \theta_i^T \Delta \theta_i} \right)^T + \frac{\Delta \theta_i \Delta \theta_i^T}{\Delta \theta_i^T \Delta \theta_i}$$

در روش BFGS اگر $\Delta \theta_i^T \Delta \theta_i > 0$ باشد Positive Definite به دست می‌آید که معنی آن اینست که S_i م. م. و $\Delta \theta_i$ در جهت $\nabla I(\theta_i)$ قرار دارد. $H_i = H_0$ (ماتریس همگرایی) $\Delta \theta_i$ (ماتریس همگرایی) $\Delta \theta_i$ (ماتریس همگرایی)

$$H_{k+1} = H_k + \frac{y_k y_k^T}{y_k^T y_k} - \frac{H_k S_k S_k^T H_k}{S_k^T H_k S_k}$$

$$\theta_{k+1} = \theta_k - H_k \nabla f(\theta_k)$$

حال به روشی دیگر از روش های بهینه‌سازی می‌پردازیم که به روش DFB معروف است.

$$\theta_{k+1} = \theta_k - \frac{y_k y_k^T}{y_k^T y_k} \nabla f(\theta_k)$$

$$H_{k+1} = H_k - \frac{H_k S_k S_k^T H_k}{S_k^T H_k S_k}$$

حال بدوین DFP و بیان:

$$P_{k+1} = P_k + \frac{S_k S_k^T}{S_k^T Y_k} - \frac{B_k Y_k Y_k^T B_k}{Y_k^T B_k Y_k} \Rightarrow \begin{cases} S_k = g_{k+1} - g_k \\ Y_k = \nabla f(x_{k+1}) - \nabla f(x_k) \end{cases}$$

سال بدوین در کلاس ترمای بیان:

تغییرات متغیرها

این بخش متناظر است با BFGS (یک اصطلاح از B_k) و فراموش می‌کند بدین معنی دارد که می‌تواند است-تغییرات را از بین ببرد.

این بخش به روز رسانی از B_k و با استفاده از صورت-متغیرها و گزینان هارابلی به صورت B_k استوار می‌شود این بخش نسبت به صورت-متغیر اصلی دارد:

سویه نوری است از دل به روز رسانی B_k را تغییر می‌دهد باید با به باجه می‌شود با B_k به روز رسانی می‌شود و در ادامه آن تغییر را می‌توان دید که تغییرات را از بین می‌برد (این روش به $O(n)$ می‌رسد و به همین دلیل گزینان)

حال بدوین گزینان متغیرها بدین معنی که اگر g_k و g_{k+1} از روش تغییرات را از بین می‌برد و به همین دلیل $O(n)$ می‌رسد و در ادامه آن تغییر را می‌توان دید که تغییرات را از بین می‌برد (این روش به $O(n)$ می‌رسد و به همین دلیل گزینان)

بدین روش (جبرانی) $P_i = \frac{g_i}{g_i^T g_i} - \frac{B_i P_{i-1}}{g_{i-1}^T B_i P_{i-1}}$ $\Rightarrow P_{i+1} = P_i - d_i P_i$

لایه $\frac{g_i^T g_i}{g_i^T g_i} = \frac{g_i^T g_i}{g_i^T g_i} = 1$ $\frac{g_i^T g_i}{g_i^T g_i} = 1$

در روش‌های دیگر هم می‌توانیم $\text{Nonlinear least squares}$ و $\text{Levenberg-Marquardt}$ را به کار ببریم که در روش‌های گزینان و روش

ادرس سوال 2: اوریس گارسی نوین این کورس: باید تمام این که به سمت چپ حرکت خطاها بسازد.

$$J(\theta) = \sum_{i=1}^N f(i, \theta) = \frac{1}{2} \sum_{i=1}^N f(i, \theta)$$

$$\frac{\partial J}{\partial \theta} = \nabla J(\theta) = J = \left(\frac{\partial J}{\partial \theta_1}, \dots, \frac{\partial J}{\partial \theta_n} \right)^T$$

$$= \sum_{i=1}^N f(i, \theta) \frac{\partial f(i, \theta)}{\partial \theta_j} \quad j=1, 2, \dots, n$$

تدریس

$$\Rightarrow \frac{\partial J}{\partial \theta} = \sum_{i=1}^N \nabla f(i, \theta)$$

$$H(\theta) = \frac{\partial^2 J}{\partial \theta_i \partial \theta_j} = \sum_{i=1}^N \frac{\partial^2 f(i, \theta)}{\partial \theta_i \partial \theta_j}$$

از این مقدار استفاده می‌کنیم

در این نقطه: θ_i

و نتایج

$$\Rightarrow H(\theta) = \sum_{i=1}^N \nabla^2 f(i, \theta)$$

$$\Rightarrow \theta_{i+1} = \theta_i - \alpha_i H^{-1}(\theta_i) \nabla J(\theta_i) = \left(\sum_{i=1}^N \nabla^2 f(i, \theta) \right)^{-1} \sum_{i=1}^N \nabla f(i, \theta)$$

$$\Rightarrow \theta_{i+1} = \theta_i - \alpha_i \left(\sum_{i=1}^N \nabla^2 f(i, \theta) \right)^{-1} \sum_{i=1}^N \nabla f(i, \theta) \rightarrow \text{Gauss - Newton Method}$$

Levenberg-Marquardt Method \Rightarrow Regularized version of Gauss - Newton Method

$$\left(\theta_i = \theta_i - \alpha_i \left(\sum_{i=1}^N \nabla^2 f(i, \theta) + \gamma_i I \right)^{-1} \sum_{i=1}^N \nabla f(i, \theta) \right)$$

که به این روش هم می‌گویند

سطر سوم: به سطر دوم یعنی تغییران بنابر تغییر ماتریس به مقادیر ویژه و بردار

فست (الف) $A = V \Lambda V^{-1}$ به این صورت مرتب
 بردار تغییر پذیر

(۷) به ماتریس بردارهای ویژه V و دستان از آن یک بردار ویژه V_i مربوط به مقادیر ویژه λ_i (۸) و λ_i

(۸) به ماتریس V و بردارهای ویژه V_i و دستان از آن یک بردار ویژه V_i مربوط به مقادیر ویژه λ_i (۸) و λ_i

$V = \begin{pmatrix} | & | & | & | \\ V_1 & V_2 & V_3 & V_4 \\ | & | & | & | \end{pmatrix}$ $\Lambda = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \lambda_3 & \\ & & & \lambda_4 \end{pmatrix}$

• سطر فوقاً باید به مقادیر ویژه λ_i و بردارهای ویژه V_i و دستان از آن یک بردار ویژه V_i مربوط به مقادیر ویژه λ_i (۸) و λ_i

حل آن یک معادله خطی به نام (Characteristic Equation) (۹) و λ_i و V_i و دستان از آن یک بردار ویژه V_i مربوط به مقادیر ویژه λ_i (۸) و λ_i

$A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$ $\det(A - \lambda I) = \begin{vmatrix} 4-\lambda & 1 \\ 2 & 3-\lambda \end{vmatrix} = (4-\lambda)(3-\lambda) - 2 = 0$
 $\Rightarrow \lambda^2 - 7\lambda + 10 = 0 \Rightarrow \lambda = \frac{7 \pm \sqrt{49-40}}{2} = \frac{7 \pm 3}{2} \Rightarrow \lambda_1 = 5, \lambda_2 = 2$

• حال بردارهای ویژه V_i و دستان از آن یک بردار ویژه V_i مربوط به مقادیر ویژه λ_i (۸) و λ_i

$\Rightarrow A - \lambda_1 I = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix} - 5 \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix}$

$\Rightarrow (A - \lambda_1 I)V = 0 \Rightarrow \begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} V_1 \\ V_2 \end{pmatrix} = 0$ $\begin{pmatrix} -V_1 + V_2 + 2V_1 - 2V_2 = 0 \\ V_1 - V_2 = 0 \Rightarrow V_1 = V_2 \end{pmatrix} V = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$

$\Rightarrow \lambda_2 = 2$

$\Rightarrow A - \lambda_2 I = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix} - 2 \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix}$

$\Rightarrow A = \begin{pmatrix} 1 & 1 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 5 \\ 2 \end{pmatrix} \begin{pmatrix} -2 & -1 \\ -1 & 1 \end{pmatrix}$

• به این صورت به بردارهای ویژه V_i و دستان از آن یک بردار ویژه V_i مربوط به مقادیر ویژه λ_i (۸) و λ_i

• حال بردارهای ویژه V_i و دستان از آن یک بردار ویژه V_i مربوط به مقادیر ویژه λ_i (۸) و λ_i

$\Rightarrow (A - \lambda_2 I)V = 0 \Rightarrow \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} V_1 \\ V_2 \end{pmatrix} = 0$ $\begin{pmatrix} 2V_1 + V_2 = 0 \\ 2V_1 + V_2 = 0 \end{pmatrix} V = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$

تست ۱: برای هر یک از روش های فوق، مقدار λ را تعیین کنید و برای آن مقدار λ مقدار λ را تعیین کنید. (استفاده از کد)

تست ۲: برای هر یک از روش های فوق، مقدار λ را تعیین کنید و برای آن مقدار λ مقدار λ را تعیین کنید. (استفاده از کد)

در حال حاضر باید به عنوان تغییر در مقدار λ در H بدانیم $H(n) \cdot \nabla \lambda \nabla^{-1} = \nabla \lambda \nabla^{-1}$

زیر آن استفاده می شود: $\lambda = \epsilon I + \lambda^A$

اگر این گونه که تغییر در λ را به λ^A اضافه می کنیم. (استفاده از کد)

در اینجا ما می خواهیم مقدار λ را تغییر دهیم. (استفاده از کد)

به عنوان مثال، در اینجا λ را تغییر می دهیم. (استفاده از کد)

باید به صورت $\lambda_{k+1} = \lambda_k - H(\lambda_k)^{-1} \nabla f(\lambda_k)$ به روز رسانی کنیم. (استفاده از کد)

حالت ج: $f(x_1, x_2) = 4x_1^3 + 3x_1x_2 + 5x_2^2 + 2x_1^2x_2$

در نقطه $\lambda^{(0)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ خواص: $\nabla f(\lambda) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 12x_1^2 + 3x_2 + 4x_1x_2 \\ 3x_1 + 10x_2 + 2x_1^2 \end{pmatrix}$

در $\lambda = (1, 0) \Rightarrow \nabla f(\lambda^{(0)}) = \begin{pmatrix} 12 \\ 3 \end{pmatrix} \Rightarrow H(\lambda) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{pmatrix} = \begin{pmatrix} 24x_1 & 4x_1 \\ 4x_1 & 10 \end{pmatrix}$

$\frac{\partial^2 f}{\partial x_1^2} = 24x_1 + 4x_2$ / $\frac{\partial^2 f}{\partial x_1 \partial x_2} = 3 + 4x_1$

$\Rightarrow H(\lambda) = \begin{pmatrix} 24x_1 + 4x_2 & 3 + 4x_1 \\ 3 & 10 \end{pmatrix}$

$\frac{\partial^2 f}{\partial x_2 \partial x_1} = 3 + 4x_1$ / $\frac{\partial^2 f}{\partial x_2^2} = 10$

$= \begin{pmatrix} 24 & 7 \\ 7 & 10 \end{pmatrix} = \begin{pmatrix} 24 & 7 \\ 7 & 10 \end{pmatrix}$

حل جایی را بنویسید که مشتق صفر باشد از تابعی مقادیر و به آن استفاده می‌کنیم

$$\det(H - \lambda I) = \begin{vmatrix} 24-\lambda & 7 \\ 7 & 10-\lambda \end{vmatrix} = (24-\lambda)(10-\lambda) - 49 = 240 - 34\lambda + \lambda^2 - 49$$

$$\Rightarrow \lambda = \frac{34 \pm \sqrt{398}}{2} = \frac{34 \pm 19.798}{2}$$

$$-\lambda^2 - 39\lambda + 191 = 0$$

$$\lambda_1 = 26.8995$$

$$\lambda_2 = 7.1005$$

حل جایی که در مشتق و به مقادیر و به آن استفاده می‌کنیم

حل جایی که در مشتق و به مقادیر و به آن استفاده می‌کنیم

$$q_{k+1} = q_k - \frac{H(q_k)^{-1} \nabla f(q_k)}{\left(\begin{matrix} 12 \\ 5 \end{matrix} \right)}$$

$$H = \begin{pmatrix} 24 & 7 \\ 7 & 10 \end{pmatrix} \rightarrow H^{-1} = \frac{1}{191} \begin{pmatrix} 10 & -7 \\ -7 & 24 \end{pmatrix}$$

$$\rightarrow H^{-1} \nabla f(q_1) = \frac{1}{191} \begin{pmatrix} 10 & -7 \\ -7 & 24 \end{pmatrix} \begin{pmatrix} 12 \\ 5 \end{pmatrix} = \frac{1}{191} \begin{pmatrix} 85 \\ 36 \end{pmatrix} = \begin{pmatrix} 0.445 \\ 0.1885 \end{pmatrix}$$

$$\Rightarrow q_1 = 11_0 - H^{-1} \nabla f(q_0) = \begin{pmatrix} 4 \\ 0 \end{pmatrix} - \begin{pmatrix} 0.445 \\ 0.1885 \end{pmatrix} = \begin{pmatrix} 3.5545 \\ -0.1885 \end{pmatrix}$$

حل جایی که در مشتق و به مقادیر و به آن استفاده می‌کنیم